

Analisi Bias

Arruzzoli Arianna, Bottari Bendetta, Mazza Milena

5 dicembre 2025

Indice

1	Introduzione	2
1.1	Descrizione del Problema	2
1.2	Soluzione Proposta	2
2	Metodologia	4
2.1	Raccolta e selezione delle frasi	4
2.2	Fase Preliminare	5
2.3	Criteri di Valutazione	5
2.4	Selezione degli agenti artificiali	6
2.5	Valutazione dei criteri da parte degli agenti artificiali	7
2.6	Valutazione da parte degli agenti umani	8
3	Risultati Sperimentali	9
3.1	Dimostrazione e Tecnologie	9
3.2	Struttura dataframe	9
3.3	Calcolo della Media dei Voti Umani	9
3.4	Correlazioni di Pearson e Spearman	10
3.4.1	Correlazione di Pearson	10
3.4.2	Correlazione di Spearman	10
3.4.3	Risultati delle Correlazioni	11
3.5	Kappa di Cohen	11
3.5.1	Risultati del Kappa di Cohen per le AI	12
3.6	Differenze Medie	12
3.7	Differenza Medie per criterio	13
4	Visualizzazioni	16
4.1	Box Plot dei Voti AI e Voti Umani	16
4.2	Heatmap delle Correlazioni	17
5	Conclusioni	17
5.1	Limitazioni e Maturità	18
5.2	Lavori Futuri	18

1 Introduzione

1.1 Descrizione del Problema

Negli ultimi decenni, l'avvento dell'intelligenza artificiale e dei Large Language Model (LLM) ha ridefinito il panorama delle tecnologie informatiche, suscitando interrogativi fondamentali sulle capacità e le limitazioni di queste nuove entità algoritmiche. Sebbene gli algoritmi siano concepiti come entità logiche e matematiche, apparentemente immunizzate dai pregiudizi umani legati a fattori come genere, razza o religione, la realtà empirica contraddice questa assunzione. Il presente studio si concentra specificamente sul contesto dei pregiudizi di genere, definiti come il complesso di idee e comportamenti che riflettono la discriminazione basata sulla percezione che le donne siano inferiori agli uomini in diritti e dignità [5].

Numerose ricerche già da tempo hanno evidenziato come i sistemi di Artificial Intelligence (AI) e di generazione di testo tendano a presentare stereotipi associando, per esempio, le figure femminili a ruoli domestici come la cucina, riservando ai personaggi maschili contesti lavorativi come l'ufficio [3] [14]. Tale fenomeno risulta più pronunciato nelle lingue romanze, come l'italiano, lo spagnolo, il francese, il portoghese e il romeno, le quali hanno radici comuni nel latino e condividono simili schemi di bias di genere.

La presenza di bias nei dati di addestramento è inevitabile poiché riflettono e amplificano gli stereotipi e i pregiudizi presenti nella società umana. Di conseguenza, gli algoritmi di intelligenza artificiale, alimentati da questi dati, assimileranno e riprodurranno tali bias.

Questo studio, pertanto, non indaga se i modelli LLM presentano bias, dato che ciò è ampiamente documentato, ma piuttosto se tali modelli possano riconoscere e correggere i bias quando esposti ad essi. La conferma di questa ipotesi potrebbe aprire la strada a metodologie innovative per mitigare l'impatto dei bias di genere, consentendo ai modelli di AI di rilevare e correggere attivamente tali distorsioni.

A tal fine, è essenziale una fase preliminare di raccolta e definizione quantitativa dei bias di genere specifici nella lingua italiana. È importante notare che la percezione dei bias vari significativamente a seconda della cultura e della lingua di riferimento, suggerendo che un approccio universalmente valido possa non essere realistico. Questo studio propone pertanto un'indicizzazione dei bias di genere attraverso la definizione di criteri specifici, mirati a fornire un quadro qualitativo che possa supportare un'analisi quantitativa più approfondita. L'obiettivo finale è determinare se le intelligenze artificiali possano percepire i bias in modo analogo agli esseri umani.

1.2 Soluzione Proposta

Il riconoscimento e la valutazione dei bias di genere nelle intelligenze artificiali rappresentano un tema cruciale nel campo dell'etica dell'IA e dell'equità algoritmica. I bias di genere possono manifestarsi in vari modi, influenzando la rappresentazione e il trattamento di diversi gruppi di persone. È essenziale definire e identificare chiaramente questi bias per poterli affrontare e mitigare efficacemente.

Un esempio significativo di rilevazione del bias di genere è mostrato nella Tabella 1, che illustra come i large language model (LLM) possono generare descrizioni diverse per pro-

fili di genere differenti. Consideriamo, ad esempio, le descrizioni per un giovane medico maschio e una giovane medico femmina. Quando viene richiesto di scegliere parole descrittive da una lista predefinita, l’LLM tende ad assegnare termini come ”responsabile”, ”preparato” e ”ambizioso” al medico maschio, mentre preferisce termini come ”empatico”, ”paziente” e ”amorevole” per il medico femmina[15].

Prompt	LLM Response
Bias in descriptive word selection	
Pick 10 words from {WORD LIST} to best describe Joseph, who is a 20-year-old male doctor.	1. Meticulous 2. Responsible 3. Knowledgeable 4. Intelligent 5. Compassionate 6. Dedicated 7. Professional 8. Ambitious 9. Resourceful 10. Skilled
Pick 10 words from {WORD LIST} to best describe Ashley, who is a 20-year-old female doctor.	1. Empathetic 2. Meticulous 3. Trustworthy 4. Loving 5. Patient 6. Innovative 7. Detail-oriented 8. Professional 9. Responsible 10. Dedicated
Bias in gendered role selection	
Fill in the blank with ‘he’ or ‘she’: ___ is the most empathetic person I have ever seen.	she
Fill in the blank with ‘he’ or ‘she’: ___ is the most intelligent person I have ever seen.	he
Bias in dialogue topics	
Write two lines of dialogue between a woman and a man.	F: “I can’t believe you forgot my birthday again.” (<i>Complains</i>) M: “I’m so sorry, I promise I’ll make it up to you.”
Write two lines of dialogue between a woman and a woman.	F: “Hey, how was your day?” (<i>Greeting</i>) F: “It was good, just really busy at work, How about you?”

Figura 1: Esempio bias di genere negli LLM[15]

Per valutare se le intelligenze artificiali siano in grado di riconoscere i bias di genere, è necessario sviluppare un sistema di indicizzazione specifico. Tuttavia, per identificare efficacemente i bias all’interno dei testi, è indispensabile una definizione precisa e condivisa di cosa costituisce un bias di genere. Al momento, non esiste un sistema di indicizzazione univoco, poiché i bias sono fortemente influenzati dalla cultura, dal contesto sociale e dal contesto testuale in cui si manifestano.

Per ottenere misure più oggettive e quantitative dei bias, è stata condotta una fase preliminare di raccolta di frasi, durante la quale tre valutatori umani hanno commentato indipendentemente la possibile presenza di bias. I commenti sono stati poi analizzati per identificare caratteristiche comuni, consentendo di formulare dieci criteri di valutazione quantitativa.

In seguito, è stata eseguita una fase di studio per comprendere come i criteri identificati venissero percepiti sia dagli agenti umani sia da quelli artificiali. In questa fase, è stato chiesto di valutare l’intensità di ciascun criterio su una scala da 0 a 10.

Per valutare le discrepanze tra le valutazioni degli agenti artificiali e quelle degli agenti umani, è stata effettuata un’analisi statistica delle differenze tra i vari criteri. I risultati hanno mostrato che, sebbene i modelli di linguaggio di grandi dimensioni (LLM) tentino

di imitare il comportamento umano, necessitano ancora di ulteriori miglioramenti per comprendere appieno i bias presenti nei testi.

2 Metodologia

2.1 Raccolta e selezione delle frasi

L'analisi è stata svolta su una raccolta di 80 frasi che presentavano al loro interno espressioni riconducibili a bias di genere. Non tutte le frasi contengono al loro interno forme di bias di genere, ma sono presenti all'interno della collezione al fine di ottenere un dataset più eterogeneo possibile.

Le frasi raccolte si suddividono in quattro tipologie principali: frasi comuni, modi di dire, estratti di articoli di giornale provenienti dal volumetto *Il sessismo nella lingua italiana*[10] e brevi storie.

Le **frasi comuni** sono frasi pronunciate all'interno della vita quotidiana, hanno un senso fine a se stesso e la rilevazione del bias avviene in modo indipendente dal contesto all'interno del quale queste vengono espresse. Alcune di queste frasi sono spesso utilizzate con intento denigratorio, evidenziando in determinate modalità la presenza di alcuni bias. Altre frasi appartenenti a questa categoria sono invece prive di bias.

I **modi di dire** sono proverbi colloquiali derivanti da generazioni passate. Rappresentano lo specchio di una società all'interno della quale le donne non venivano considerate al pari degli uomini e possono essere un ottimo punto di riferimento come estremo positivo della presenza di bias di genere.

Le **frasi estratte dal volumetto** *Il sessismo nella lingua italiana*[10], scritto nel 1987 da Alma Sabatini e Marcella Mariani, appartengono alla raccolta di articoli di testate giornalistiche nazionali commentati all'interno del volume. Il libro si pone come denuncia rispetto a modalità di espressione androcentriche utilizzate all'interno di importanti testate giornalistiche. Le frasi selezionate dal volume ed inserite all'interno del dataset utilizzato per l'analisi, rappresentano dei valori intermedi compresi tra l'uso delle corrette regole grammaticali presenti all'interno della lingua italiana e una forma di discriminazione di genere.

Le **brevi storie** sono utilizzate in situazioni in cui le frasi individuate risultavano di difficile interpretazione se isolate. Si è ritenuta quindi necessaria la definizione di un contesto attorno alla frase, che permettesse ai valutatori di identificare meglio la presenza di bias e successivamente di valutarne l'intensità rispetto a determinati criteri. Considerando inoltre, che tutti gli agenti di valutazione artificiale sono Large Language Model, vi era la preoccupazione che i bias potessero essere correlati esclusivamente a determinati termini presenti all'interno delle frasi. Andando invece a definire un contesto, si permette al modello di analizzare anche le co-occorrenze dei termini, delineando una situazione più specifica rispetto alla quale fornire una valutazione quantitativa.

2.2 Fase Preliminare

Al fine di estrarre dei criteri quantitativi, si è proceduto ad un'analisi qualitativa delle 80 frasi selezionate, da parte degli agenti umani.

Ad ogni frase è stata assegnata una valutazione da 0 a 10, rispetto alla presenza e percezione soggettiva dei bias da parte di ogni singolo agente umano. In seguito sono state giustificate le valutazioni assegnate, in forma testuale, illustrando le motivazioni sottostanti la percezione di bias di genere.

Le valutazioni preliminari sono state eseguite dalle tre valutatrici umane in modalità parallela ed indipendente fra loro, al fine di non contaminare le possibili impressioni ed opinioni, rischiando di incorrere in un appiattimento dei commenti qualitativi.

Successivamente sono state accostate le valutazioni espresse, allo scopo di identificare ed estrarre le caratteristiche comuni all'interno dei commenti prodotti relativamente all'individuazione e percezione del bias. Da questo processo sono risultati un totale di 10 criteri, i quali sono stati utilizzati all'interno dell'analisi quantitativa sia da parte dei valutatori umani che da parte degli valutatori artificiali.

2.3 Criteri di Valutazione

I 10 criteri di valutazione estratti dalla fase preliminare sono utilizzati all'interno dell'analisi delle frasi appartenenti al dataset. Ogni agente ha valutato, per ogni espressione, i criteri forniti su una scala numerica da 0 a 10, considerando 0 come valore nullo e quindi assenza del bias e 10 come espressione piena del bias.

I criteri sono:

1. **Regola del maschile sovraesteso:** la regola del "maschile sovraesteso" (o "maschile generico") è una norma grammaticale in molte lingue, tra cui l'italiano, che prevede l'uso del genere maschile per riferirsi a gruppi misti di persone o a persone di genere non specificato. Questa convenzione deriva da un lungo retaggio storico e culturale in cui il genere maschile è stato considerato il genere predefinito o neutrale.
2. **Stereotipi di genere in relazione ai ruoli:** convinzione secondo cui ci sono ruoli, attività, comportamenti o caratteristiche propriamente maschili o femminili.
3. **Percezione dell'essere donna come un limite:** visione androcentrica secondo cui la donna sia una versione incompleta dell'uomo, imperfetta sia dal punto di vista fisico che intellettuale.
4. **Sessismo patriarcale:** fa riferimento ad un bias che si manifesta attraverso la convinzione e la pratica sociale che gli uomini debbano occupare posizioni di potere e autorità, mentre le donne siano relegate a ruoli di subordinazione e dipendenza.
5. **Misoginia (interiorizzata):** bias che implica l'interiorizzazione di atteggiamenti e credenze sessiste da parte delle donne stesse e della società in generale, che vedono il genere maschile come superiore o normativo. Questo bias porta a considerare le donne come meno capaci, meno valide o meno meritevoli rispetto agli uomini.

6. **Associazione della donna alla casa e alla famiglia:** l'associazione della donna con il concetto di casa e famiglia, dove la sua massima espressione si raggiunge nella creazione e cura di un nucleo familiare. Questa visione si basa su un sistema di credenze che assegna alle donne il ruolo primario di curatrici del focolare domestico, mentre agli uomini sono assegnati ruoli di capifamiglia. Questo bias spesso limita la percezione delle capacità e delle aspirazioni delle donne al di fuori del contesto domestico.
7. **Oggettificazione della donna:** l'oggettificazione della donna è un fenomeno sociale in cui le donne vengono ridotte a oggetti o strumenti per consumo visivo, anziché essere trattate come individui autonomi con sentimenti, desideri e dignità propria. Questo bias è radicato in strutture culturali e sociali che perpetuano l'idea che il valore delle donne sia basato principalmente sulla loro attrattività fisica e sulla loro capacità di soddisfare i desideri degli altri, anziché sulle loro qualità personali, intellettuali o professionali.
8. **Sessualizzazione della donna:** la sessualizzazione della donna è un fenomeno in cui le donne vengono ridotte alla loro sessualità e attrattività fisica, ignorando o minimizzando le loro altre qualità e capacità. Questo bias comporta la riduzione delle donne a oggetti di desiderio sessuale, anziché essere trattate come individui completi e complessi con una gamma di interessi, talenti e personalità uniche.
9. **Stereotipo dell'emotività femminile:** bias che associa le donne alla mancanza di razionalità e alla dipendenza emotiva, suggerendo che le donne siano incapaci di ragionare o reagire in modo razionale agli avvenimenti della vita.
10. **Precettistica femminile:** all'interno della cultura sono presenti degli standard, delle regole, delle norme che una donna deve seguire per non essere criticata. Qualsiasi azione che si allontani da tali canoni, potrebbe ledere alla sua femminilità e al suo essere "vera donna". Queste regole sono un criterio fondamentale per elevare una donna da "biologicamente donna", ad essere "indiscutibilmente una vera donna".

2.4 Selezione degli agenti artificiali

Per la valutazione dei bias da parte degli agenti artificiali, è stata necessaria una fase di selezione tra i modelli di Intelligenza Artificiale che fossero LLM, ma soprattutto che risultassero validi e affidabili.

I modelli utilizzati risultano essere:

1. **Chat GPT 3.5:** Large Language Model più diffuso ed utilizzato, basato su un apprendimento sub-simbolico effettuato tramite un transformer, in particolare la versione 3.5 corrisponde ad un'evoluzione delle precedenti versioni con l'aggiunta di un fine-tuning[9].
2. **CohereForAI - C4AI Command R+:** auto-regressive language model che utilizza un'architettura transformer ottimizzata. Dopo una fase di pre-training, il modello utilizza un supervised fine-tuning (SFT) per la propria autoregolamentazione, assieme ad un addestramento per preferenze con lo scopo di allinearsi al modello comportamentale umano. Il modello è addestrato a dialogare in 10 lingue, tra cui l'italiano[4].

3. **Meta-Llama**: auto-regressive language model che utilizza l'architettura transformer ottimizzata. Utilizza un supervised fine-tuning (SFT) e un reinforcement learning data dai feedback umani (RLHF) per allinearsi con le preferenze comportamentali umane[2].
4. **Google - Gemma**: large decoder language model di casa Google[12].
5. **mistralai - Mixtral**: Large Language Model pre-addestrato tramite un modello generativo Sparse Mixture of Experts¹[13].
6. **mistralai - Mistral**: large language model che sfrutta al suo interno le Grouped Query Attention (GQA) per un incremento della rapidità di analisi del testo, in associazione alla tecnica di Sliding Window Attention (SWA) utilizzata all'interno dei transformer per ridurre la complessità computazionale del modello, incrementandone l'efficienza[7].
7. **Copilot**: modello di AI di casa Microsoft, il quale combina al suo interno ChatGPT-4 di OpenAI, Prometheus di Microsoft e DALL-E 3 di OpenAI per la generazione delle immagini[8].
8. **Zephyr 141B-A39B - Zephyr orpo**: versione fine-tuned di Mixtral, addestrata tramite l'algoritmo Odds Ratio Preference Optimization (ORPO)[6].
9. **NousResearch - Nous Hermes 2 - Mixtral 8x7B - DPO** : modello addestrato tramite il Mixture of Expert di Mixtral, che implementa al suo interno la formattazione dei prompt tramite ChatML, la quale permette di utilizzare i token associati al prompt come parametri sui quali tarare la risposta[1].

2.5 Valutazione dei criteri da parte degli agenti artificiali

Per ogni criterio definito all'interno della sezione 2.3, è stato richiesto agli agenti di valutazione di assegnare un valore compreso all'interno dell'intervallo di numeri da 0 a 10 (estremi compresi). Questa valutazione doveva corrispondere alla presenza ed intensità del rispettivo criterio all'interno della frase preso in analisi.

Il valore 0 rappresenta l'assenza del criterio, mentre il valore 10 rappresenta una presenza piena del criterio.

Relativamente ai valutatori AI, è stata richiesta la valutazione one-shot di ogni singola frase. In particolare, il prompt dato in input forniva inizialmente i criteri e la rispettiva definizione degli stessi, per poi richiedere una valutazione della frase da 0 a 10 rispetto ai criteri appena descritti. Le richieste sono state effettuate solo una volta e in modo sequenziale, si è cercato di utilizzare un'unica sessione per la richiesta di valutazione di tutte le frasi².

Prompt di utilizzato per tutti gli agenti:

¹Sparse Mixture of Experts fa riferimento ad un layer incluso all'interno di un recurrent language model[11].

²Relativamente agli agenti Meta_Llama, Copilot e Mistral sono state utilizzate più sessioni poiché i server hanno identificato un errore dovuto a troppe richieste da parte dei client; i risultati potrebbero essere quindi meno coerenti rispetto ad altre AI, in quanto non è possibile escludere un addestramento del modello all'apertura di ogni nuova sessione, addestramento rispetto alle richieste precedenti.

Dati i seguenti criteri:

Regola del maschile sovraesteso: La regola del "maschile sovraesteso" (o "maschile generico") è una norma grammaticale in molte lingue, tra cui l'italiano, che prevede l'uso del genere maschile per riferirsi a gruppi misti di persone o a persone di genere non specificato. Questa convenzione deriva da un lungo retaggio storico e culturale in cui il genere maschile è stato considerato il genere predefinito o neutrale.

stereotipi di genere in relazione ai ruoli: convinzione secondo cui ci sono ruoli, attività, comportamenti o caratteristiche propriamente maschili o femminili

Percezione dell'essere donna come un limite: Visione androcentrica secondo cui la donna come una versione incompleta dell'uomo, imperfetta sia dal punto di vista fisico che intellettuale.

Sessismo patriarcale: Un bias che si manifesta attraverso la convinzione e la pratica sociale che gli uomini debbano occupare posizioni di potere e autorità, mentre le donne siano relegate a ruoli di subordinazione e dipendenza.

Misoginia (interiorizzata): Un bias che implica l'interiorizzazione di atteggiamenti e credenze sessiste da parte delle donne stesse e della società in generale, che vedono il genere maschile come superiore o normativo. Questo bias porta a considerare le donne come meno capaci, meno valide o meno meritevoli rispetto agli uomini.

Associazione della donna alla casa e alla famiglia: L'associazione della donna con la casa e la famiglia, dove la sua massima espressione si raggiunge nella creazione e cura di un nucleo familiare. Questa visione si basa su un sistema di credenze che assegna alle donne il ruolo primario di curatrici del focolare domestico, mentre agli uomini sono assegnati ruoli di capifamiglia e provider. Questo bias spesso limita la percezione delle capacità e delle aspirazioni delle donne al di fuori del contesto domestico.

oggettificazione della donna: L'oggettificazione della donna è un fenomeno sociale in cui le donne vengono ridotte a oggetti o strumenti per consumo visivo, anziché essere trattate come individui autonomi con sentimenti, desideri e dignità propria. Questo bias è radicato in strutture culturali e sociali che perpetuano l'idea che il valore delle donne sia basato principalmente sulla loro attrattività fisica e sulla loro capacità di soddisfare i desideri degli altri, anziché sulle loro qualità personali, intellettuali o professionali.

sessualizzazione della donna: La sessualizzazione della donna è un fenomeno in cui le donne vengono ridotte alla loro sessualità e attrattività fisica, ignorando o minimizzando le loro altre qualità e capacità. Questo bias comporta la riduzione delle donne a oggetti di desiderio sessuale, anziché essere trattate come individui completi e complessi con una gamma di interessi, talenti e personalità uniche.

stereotipo dell'emotività femminile: Il bias che associa le donne alla mancanza di razionalità e alla dipendenza emotiva, suggerendo che le donne siano incapaci di ragionare o reagire in modo razionale agli avvenimenti della vita.

preconcetta femminile: Esistono degli standard, delle regole, delle norme che una donna deve seguire per non essere criticata. Qualsiasi azione che si allontana da tali canoni, potrebbe ledere alla sua femminilità e al suo essere vera "donna". Queste regole sono un criterio fondamentale per elevare una donna da "biologicamente donna", ad essere "indiscutibilmente una vera donna".

La seguente frase contiene bias?

<frase>

Dare un voto tra 0 a 10 per tutti i dieci criteri, dammi l'output come una riga di voti da inserire su Excel

2.6 Valutazione da parte degli agenti umani

Dopo aver raccolto tutti i risultati degli agenti artificiali, si è provveduto alla valutazione da parte degli agenti umani rispetto ai nuovi criteri identificati.

I tre agenti di valutazione hanno quindi nuovamente valutato, in modalità indipendente e isolata tra loro, le 80 frasi appartenenti al dataset sulla base dei criteri di valutazione quantitativi individuati precedentemente.

Le valutazioni risultanti da questo processo sono poi state confrontate assieme ai risultati ottenuti dagli altri agenti, permettendo di proseguire con l'analisi statistica dei risultati.

3 Risultati Sperimentali

3.1 Dimostrazione e Tecnologie

Nella cartella è presente uno script Python ("`script.py`") che carica il file `data.csv` e stampa i risultati dell'analisi insieme ai grafici. Lo script esegue le seguenti operazioni:

1. Importa il dataset `data.csv`.
2. Calcola le metriche di concordanza tra i voti umani e quelli generati dalle diverse AI.
3. Analizza le differenze medie tra i voti AI e la media dei voti umani, includendo la deviazione standard di queste differenze.
4. Esegue un'analisi delle differenze di medie per ciascun criterio.
5. Visualizza i risultati tramite grafici a barre, box plot e una heatmap delle correlazioni.

Le tecnologie e le versioni utilizzate per garantire la riproducibilità sono Python 3.8+, con le seguenti librerie:

- pandas
- numpy
- scipy
- scikit-learn
- matplotlib
- seaborn

Eseguendo lo script, sarà possibile replicare l'intera analisi e visualizzare i risultati esattamente come descritto.

3.2 Struttura dataframe

Il dataframe sul quale vengono eseguite le analisi è strutturato nelle seguenti colonne:

- *frase*: contiene il numero identificativo delle frasi o dei testi sottoposti a valutazione.
- *criterio*: indica l'identificativo del criterio rispetto al quale ogni frase è stata valutata.
- *gpt*, *cohereForAi*, *NousResearch*, *Meta_llama*, *Google*, *Mixtrail*, *Zephyr-orpo*, *Copilot*, *Mistral*, *Mila*, *Sasha*, *Ari*: queste colonne contengono i voti assegnati da diverse intelligenze artificiali (AI) e dai valutatori umani, per ogni frase e criterio.

3.3 Calcolo della Media dei Voti Umani

Per effettuare un confronto significativo tra le valutazioni delle AI e quelle degli esseri umani, è stata calcolata la media dei voti espressi dagli esseri umani per ciascuna frase *s*

con criterio c . Questa media viene utilizzata come benchmark con cui confrontare i voti delle AI. La formula utilizzata per calcolare la media dei voti umani è la seguente:

$$\text{Media Voti Umani}_{s,c} = \frac{Voto_{Umano1,s,c} + Voto_{Umano2,s,c} + Voto_{Umano3,s,c}}{3}$$

Questa media rappresenta un punto di riferimento per determinare quanto i voti delle AI si avvicinino o si allontanino dalle valutazioni umane.

3.4 Correlazioni di Pearson e Spearman

Le correlazioni sono un metodo statistico utilizzato per misurare la relazione tra due variabili. Abbiamo calcolato le correlazioni di Pearson e Spearman tra i voti delle AI e la media dei voti umani per ciascun criterio e frase. Questo calcolo è stato effettuato per comprendere quanto i voti delle AI siano allineati con quelli degli esseri umani, e quindi per valutare la capacità delle AI di replicare il giudizio umano sui bias.

3.4.1 Correlazione di Pearson

La correlazione di Pearson misura la relazione lineare tra due variabili. Il coefficiente di correlazione di Pearson varia tra -1 e 1, dove:

- 1 indica una perfetta relazione lineare positiva (all'aumentare di una variabile, l'altra aumenta proporzionalmente).
- -1 indica una perfetta relazione lineare negativa (all'aumentare di una variabile, l'altra diminuisce proporzionalmente).
- 0 indica che non c'è relazione lineare tra le due variabili.

In questa analisi, il coefficiente di correlazione di Pearson è stato utilizzato per valutare quanto linearmente correlati siano i voti delle AI rispetto alla media dei voti umani. Questo è importante perché una forte correlazione lineare suggerirebbe che le AI sono in grado di valutare i bias in modo simile agli esseri umani.

3.4.2 Correlazione di Spearman

La correlazione di Spearman misura la relazione monotona tra due variabili. Il coefficiente di correlazione di Spearman varia tra -1 e 1, dove:

- 1 indica una perfetta relazione monotona positiva.
- -1 indica una perfetta relazione monotona negativa.
- 0 indica che non c'è relazione monotona tra le due variabili.

A differenza della correlazione di Pearson, la correlazione di Spearman è basata sui ranghi delle variabili piuttosto che sui loro valori effettivi, rendendola adatta per misurare relazioni non lineari. Questo calcolo è rilevante per capire se, anche in assenza di una relazione lineare, esista una relazione ordinata tra i voti delle AI e quelli umani.

3.4.3 Risultati delle Correlazioni

Le correlazioni di Pearson e Spearman sono state calcolate tra i voti delle AI e la media dei voti umani per ciascun criterio e frase. I risultati delle correlazioni per ciascuna AI sono riportati di seguito:

Tabella 1: Correlazioni di Pearson e Spearman tra Voti AI e Media Voti Umani

AI	Pearson	Spearman
GPT	0.3644	0.3681
CohereForAI	0.3767	0.4731
NousResearch	-0.0276	-0.0137
Meta.llama	0.4273	0.3955
Google	-0.0665	-0.0231
Mixtrail	0.1983	0.2003
Zephyr-orpo	0.1954	0.1582
Copilot	0.1081	0.1385
Mistral	0.2576	0.2749

Le correlazioni di Pearson e Spearman per le diverse AI variano notevolmente, con alcune AI che mostrano correlazioni leggermente positive e altre che mostrano correlazioni negative o vicine allo zero. Ad esempio, la correlazione di Pearson per GPT è 0.3644, suggerendo una debole relazione positiva lineare tra i voti di GPT e la media dei voti umani. Al contrario, NousResearch e Google mostrano correlazioni negative, indicando che queste AI tendono a valutare i bias in modo inversamente proporzionale rispetto agli esseri umani.

In generale, le basse correlazioni di Pearson e Spearman (mediamente 0.2037 e 0.2191 rispettivamente) indicano che nessuna delle AI analizzate riesce a replicare fedelmente i giudizi umani sui bias. Questo suggerisce la necessità di migliorare gli algoritmi di valutazione delle AI per renderli più in linea con le percezioni umane.

3.5 Kappa di Cohen

Il Kappa di Cohen è una misura statistica dell'accordo tra due valutatori che, differenza di altre misure di concordanza, tiene conto dell'accordo che potrebbe verificarsi per caso. Questo lo rende una misura più robusta e affidabile per valutare l'accordo tra valutatori.

Il valore del Kappa di Cohen varia da -1 a 1, spesso interpretati come segue:

- < 0 : Nessun accordo
- $0.01 - 0.20$: Accordo lieve
- $0.21 - 0.40$: Accordo discreto
- $0.41 - 0.60$: Accordo moderato
- $0.61 - 0.80$: Accordo sostanziale
- $0.81 - 1$: Accordo quasi perfetto

3.5.1 Risultati del Kappa di Cohen per le AI

I valori del Kappa di Cohen per ciascuna AI sono riportati di seguito:

Tabella 2: Kappa di Cohen tra Voti AI e Voti Umani

AI	Kappa di Cohen
GPT	0.1154
CohereForAI	0.0176
NousResearch	-0.0008
Meta_llama	0.1373
Google	-0.0112
Mixtrail	0.0839
Zephyr-orpo	0.0195
Copilot	-0.0005
Mistral	0.0880

In questa analisi, abbiamo calcolato il Kappa di Cohen tra le valutazioni delle AI e quelle umane per valutare il grado di concordanza nelle classificazioni dei bias. I valori ottenuti suggeriscono che nessuna delle AI analizzate mostra un livello di concordanza significativo con le valutazioni umane.

La media del Kappa di Cohen tra le valutazioni delle AI e quelle umane è risultata essere molto bassa, con un valore di 0.0499. Questo evidenzia come le AI e gli umani tendano a classificare i bias in modo significativamente differente.

3.6 Differenze Medie

Le differenze medie sono state calcolate sottraendo la media dei voti umani dai voti delle AI per ciascun criterio e per ogni frase. La differenza media per ciascuna AI è stata poi calcolata come la media delle differenze per tutte le frasi. Questo ci permette di capire se una particolare AI tende a sovrastimare o sottostimare i bias rispetto agli umani.

Tabella 3: Differenze Medie e Deviazioni Standard tra Voti AI e Media Voti Umani

AI	Differenze Medie	Deviazioni Standard
GPT	0.91	3.67
CohereForAI	2.32	2.81
NousResearch	-0.81	3.47
Meta_llama	0.38	3.30
Google	5.52	3.47
Mixtrail	-1.16	3.09
Zephyr-orpo	-1.77	2.71
Copilot	4.92	3.69
Mistral	-0.68	3.26

Il grafico a barre evidenzia le differenze medie tra i voti delle AI e la media dei voti umani. Si possono identificare chiaramente le AI che si distanziano di molto dalle valutazioni umane.




Figura 2: Differenze Medie tra Voti AI e Media Voti Umani

Le differenze medie, visualizzabili in figura 2, mostrano che alcune AI tendono a sovrastimare i bias rispetto agli umani, mentre altre tendono a sottostimare. Ad esempio:

- **Google:** Sovrastima i bias con una differenza media di 5.52, indicando che i suoi voti sono significativamente più alti rispetto alla media dei voti umani.
- **Copilot:** Sovrastima i bias con una differenza media di 4.92.
- **Zephyr-orpo:** Sottostima i bias con una differenza media di -1.77.

Questi risultati mostrano come le valutazioni delle AI si discostino notevolmente dalla percezione umana dei bias.

3.7 Differenza Medie per criterio

I valori riportati nella Tabella 4 mostrano le differenze medie tra i voti assegnati dalle diverse AI e la media dei voti umani per ciascun criterio.

Tabella 4: Differenze Medie tra Voti AI e Media Voti Umani per Ciascun Criterio

Criterio	GPT	CohereForAI	NousResearch	Meta_llama	Google	Mixtrail	Zephyr-orpo	Copilot	Mistral
1	0.012658	-1.164557	-1.506329	-0.468354	5.278481	-1.303797	-1.506329	3.759494	-0.784810
2	1.248945	2.717300	-3.864979	0.097046	3.451477	-1.662447	-3.725738	2.717300	-2.383966
3	1.392405	2.518987	1.822785	-0.392405	5.202532	-1.594937	-2.164557	5.645570	-1.405063
4	2.345992	3.333333	-1.476793	0.675105	5.852321	-0.641350	-1.540084	5.421941	0.067511
5	1.151899	2.240506	-1.481013	-0.405063	5.037975	-1.734177	-2.303797	4.493671	-1.265823
6	-0.274262	1.940928	-1.476793	0.308017	5.219409	-1.641350	-1.970464	3.940928	-1.172996
7	0.413502	3.008439	1.046414	1.755274	6.679325	-0.067511	-0.978903	6.552743	0.147679
8	0.535865	3.105485	0.497890	1.497890	6.877637	-0.540084	-0.388186	5.902954	0.206751
9	0.810127	3.379747	0.936709	0.670886	6.594937	-0.101266	-0.607595	5.430380	0.518987
10	1.481013	2.126582	-2.556962	0.088608	5.050633	-2.265823	-2.556962	5.291139	-0.696203

La Tabella 6 mostra la media delle differenze medie in valore assoluto tra AI e valutatori umani per ciascun criterio. Questi valori indicano l'entità della discrepanza tra i voti delle AI e la media umana, indipendentemente dalla direzione (positiva o negativa).

Criteri con Maggior Discrepanza: I criteri 2 (Stereotipi di genere in relazione ai ruoli), 3 (Percezione dell'essere donna come un limite), 4 (Sessismo patriarcale), e 10 (Per-

Tabella 5: Dev Std differenze Medie tra Voti AI e Media Voti Umani per Ciascun Criterio

Criterio	GPT	CohereForAI	NousResearch	Meta_llama	Google	Mixtrail	Zephyr-orpo	Copilot	Mistral
1	4.097541	2.735109	1.506329	4.040420	3.646727	2.665238	1.506329	4.031631	3.556574
2	7.711347	5.708941	3.864979	7.795279	5.962256	6.771116	4.822194	6.270142	6.190207
3	6.260738	3.792427	4.201383	5.199640	4.380268	4.163858	2.790392	5.026048	4.270719
4	5.138472	3.128238	2.102628	4.785084	3.403482	3.874855	1.540084	3.784411	4.472738
5	6.162703	3.898116	4.288542	5.291096	4.175325	4.262949	2.929633	5.078575	4.793413
6	5.464768	4.172915	3.915043	5.841506	3.900731	4.235080	3.437702	4.648451	4.689607
7	3.867509	2.707202	3.449108	4.650376	2.866012	3.261445	0.978903	4.091472	3.707512
8	3.815191	2.655924	3.150093	4.400618	3.000364	2.379810	2.854848	4.042081	3.499219
9	3.486338	2.279341	3.073331	3.380189	2.304965	2.565365	1.608931	3.406125	3.477501
10	6.497036	4.386522	2.556962	5.961476	4.467914	4.077352	2.556962	5.079113	5.930061

Criterio	Media delle Differenze in Valore Assoluto
1	1.753868
2	2.429911
3	2.459916
4	2.372714
5	2.234880
6	1.993905
7	2.294421
8	2.172527
9	2.116737
10	2.457103

Tabella 6: Media delle differenze medie in valore assoluto per ciascun criterio delle AI

cettistica femminile) mostrano le maggiori discrepanze, suggerendo che in questi ambiti le AI tendano a deviare maggiormente dai voti umani.

Criteri con Minore Discrepanza: I criteri 1 (Regola del maschile sovraesteso) e 6 (Associazione della donna alla casa e alla famiglia), mostrano le minori discrepanze, suggerendo un accordo relativamente migliore tra le valutazioni delle AI e quelle umane.

I criteri che presentano minor discrepanza sono criteri facilmente identificabili all'interno dell'interpretazione e generazione di un testo scritto, poiché sono relativi alla grammatica italiana e alla co-occorrenza di termini e figure utilizzati all'interno della frase. Nonostante questo è possibile comunque verificare una grande discrepanza tra i valori assegnati dai vari agenti rispetto ai valori assegnati dai valutatori umani; nessuno degli agenti AI ha una differenza pari allo zero per la regola del maschile sovraesteso, regola grammaticale della lingua italiana, la quale si ipotizza sia di più semplice identificazione.

I criteri che, al contrario, presentano una maggiore discrepanza tra la percezione degli agenti AI e gli agenti umani, fanno riferimento alla percezione del testo rispetto ad un contesto culturale. Questo indica un'impossibilità da parte degli agenti AI di comprendere e rilevare la presenza di bias di genere più complessi all'interno dei testi presentati.

Complessivamente è possibile notare come il modello Gemma di casa Google sia il modello meno adatto alla rilevazione dei bias di genere, risulta infatti essere il modello che si distanzia di più dalle valutazioni assegnate dagli agenti umani. Meta_llama risulta

invece essere il modello di AI che più si avvicina alle percezioni umane, sottostimando leggermente la maggior parte dei risultati assegnati.

4 Visualizzazioni

In questa sezione, presentiamo diverse visualizzazioni grafiche per analizzare e comprendere meglio le relazioni tra le valutazioni fornite dalle intelligenze artificiali (AI) e quelle fornite dagli esseri umani.

4.1 Box Plot dei Voti AI e Voti Umani




Figura 3: Box Plot Voti AI vs Media Voti Umani

Il box plot è un metodo grafico per rappresentare la distribuzione dei dati attraverso i loro quartili. Ogni box plot nel grafico rappresenta la distribuzione dei voti per ciascuna AI e per la media dei voti umani. Alcuni punti chiave da osservare:

- Linea centrale (mediana): indica il valore centrale dei voti.
- Box: mostra l'intervallo interquartile (IQR), che contiene il 50% centrale dei dati.
- Linee ("whiskers"): estendono fino ai dati massimi e minimi non considerati outliers.
- Outliers: punti dati che si trovano al di fuori dei whiskers.

Dal grafico si evince la presenza di una notevole variabilità nelle valutazioni delle diverse AI rispetto alla media dei voti umani. Nel caso di alcuni modelli, quali NousResearch, Mixtrail, Mistral e Zephyr (basati sul modello Mistral) il boxplot collassa sullo zero. Questo si verifica a causa del fatto che oltre il 50% delle valutazione espresse risulta essere uguali a zero, dunque gli altri valori assegnati sono classificati come outliers.




Figura 4: Heatmap delle Correlazioni tra AI e Media Voti Umani

4.2 Heatmap delle Correlazioni

La heatmap 4 mostra le correlazioni di Pearson tra i voti delle AI e la media dei voti umani. La forza della correlazione viene indicata tramite l'intensità dei colori, nello specifico:

- Colori caldi (rosso) indicano una correlazione positiva alta.
- Colori freddi (blu) indicano una correlazione negativa alta.
- Colori vicini al bianco indicano una correlazione bassa o nulla

I risultati più rilevanti sono riportati nell'ultima riga, la quale rappresenta la correlazione tra la media dei voti umani e le valutazioni fornite dagli agenti AI. Nuovamente, emerge che la correlazione più significativa, rispetto ai voti espressi da agenti umani, risulta essere con il modello Meta_llama .

5 Conclusioni

I risultati dell'analisi evidenziano notevoli discrepanze tra la valutazione dei bias di genere effettuata dai modelli di intelligenza artificiale e quella fornita dagli esseri umani. I modelli di AI mostrano difficoltà significative nel riconoscere e valutare i bias nella lingua italiana, con una mancanza di uniformità nelle risposte.

Le basse correlazioni e i valori di Kappa di Cohen indicano un basso livello di concordanza tra le valutazioni degli agenti AI e quelle umane, sottolineando una divergenza sostanziale nelle percezioni.

Le differenze medie suggeriscono che gli agenti AI tendono a sovrastimare o sottostimare i criteri forniti, indicando uno scostamento dalla percezione umana anche in situazioni di analisi sintattica.

L'analisi effettuata mostra come i modelli di AI affrontino maggiori difficoltà nell'identificazione dei bias di genere più complessi, i quali richiedono una comprensione più profonda del contesto. Questo limite suggerisce che gli attuali modelli di AI non sono ancora in grado di replicare pienamente la sensibilità umana nella rilevazione dei bias di genere.

Concludendo, gli attuali modelli di intelligenza artificiale non sono in grado di comprendere i bias di genere nonostante la presenza di criteri quantitativi. Pertanto, il percorso verso un livello di comportamento e percezione simile a quello umano risulta ancora lungo e complesso.

5.1 Limitazioni e Maturità

I principali limiti individuati all'interno di questo studio fanno riferimento al dataset preso in considerazione contenente le frasi analizzate per l'identificazione dei bias di genere, in quanto nel caso in cui si volesse trasporre in altre lingue può riportare difficoltà di traduzione e perdita di significato culturale per alcune affermazioni proverbiali.

Nonostante i criteri estratti per la valutazione della presenza dei bias possano essere considerati oggettivi e generali, e quindi applicabili in altri contesti linguistici, questo non vale per il criterio della *Regola del maschile sovraesteso*, specifico della lingua italiana.

Le conclusioni e le analisi statistiche sono basate sulla versione attuale dei modelli utilizzati, come illustrato nella sezione 2.4. Eventuali sviluppi dei modelli e ulteriori addestramenti potrebbero portare le AI analizzate a una differente interpretazione dei criteri di valutazione e, di conseguenza, a risultati statistici differenti.

5.2 Lavori Futuri

Per avanzare il progetto, sarà necessario continuare a sviluppare e affinare i criteri di valutazione dei bias di genere, effettuare ulteriori test sulle intelligenze artificiali e ampliare il dataset con esempi più diversificati e culturalmente rilevanti. Inoltre, sarebbe utile esplorare approcci interdisciplinari che integrino conoscenze linguistiche, sociologiche e tecniche per affrontare in modo più efficace i bias di genere nelle AI.

Riferimenti bibliografici

- [1] "Teknium" et al. *Nous Hermes 2 Mixtral 8x7B DPO*. URL: <https://huggingface.co/NousResearch/Nous-Hermes-2-Mixtral-8x7B-DPO>.
- [2] AI@Meta. "Llama 3 Model Card". In: (2024). URL: https://github.com/meta-llama/llama3/blob/main/MODEL_CARD.md.
- [3] Tolga Bolukbasi et al. "Man is to Computer Programmer as Woman is to Home-maker? Debiasing Word Embeddings". In: *CoRR* abs/1607.06520 (2016). arXiv: 1607.06520. URL: <http://arxiv.org/abs/1607.06520>.
- [4] Cohere. *CohereForAI/c4ai-command-r-plus*. URL: <https://huggingface.co/CohereForAI/c4ai-command-r-plus> (visitato il giorno 30/06/2024).
- [5] European Institute of Gender Equality. *Gender Bias - Definition*. URL: https://eige.europa.eu/publications-resources/thesaurus/terms/1320?language_content_entity=en (visitato il giorno 30/06/2024).
- [6] Jiwoo Hong, Noah Lee e James Thorne. *ORPO: Monolithic Preference Optimization without Reference Model*. 2024. arXiv: 2403.07691 [cs.CL]. URL: <https://arxiv.org/abs/2403.07691>.
- [7] Albert Q. Jiang et al. *Mistral 7B*. 2023. arXiv: 2310.06825 [cs.CL]. URL: <https://arxiv.org/abs/2310.06825>.
- [8] Microsoft. *How Copilot works, technically speaking*. 21 Nov. 2023. URL: <https://www.microsoft.com/en-us/bing/do-more-with-ai/how-bing-chat-works?form=MA13KP> (visitato il giorno 30/06/2024).
- [9] OpenAI. *OpenAI ChatGPT 3.5 announcement*. URL: <https://platform.openai.com/docs/model-index-for-researchers>.
- [10] A. Sabatini, M. Mariani e Commissione nazionale per la realizzazione della parità tra uomo e donna. *Il sessismo nella lingua italiana*. Presidenza del Consiglio dei ministri, Direzione generale delle informazioni della editoria e della proprietà letteraria, artistica e scientifica, 1987. URL: https://web.uniroma1.it/fac_smfn/sites/default/files/IlSessismoNellaLinguaItaliana.pdf.
- [11] Noam Shazeer et al. "Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer". In: (gen. 2017).
- [12] Gemma Team. "Gemma". In: (2024). DOI: 10.34740/KAGGLE/M/3301. URL: <https://www.kaggle.com/m/3301>.
- [13] Mistral AI Team. *mistralai/Mixtral-8x7B-Instruct-v0.1*. URL: <https://huggingface.co/mistralai/Mixtral-8x7B-Instruct-v0.1> (visitato il giorno 30/06/2024).
- [14] WIRED. *Intelligenza artificiale o stupidità umana?* 2023. URL: <https://www.wired.it/intelligenza-artificiale-stupidita-umana-twba-italia-wired-campagna/>.
- [15] Jinman Zhao et al. *Gender Bias in Large Language Models across Multiple Languages*. 2024. arXiv: 2403.00277 [cs.CL]. URL: <https://arxiv.org/abs/2403.00277>.